

Entrega 1: Problema, Datos, EDA y Baseline

Prediccion de niveles criticos en embalses colombianos ante El Nino 2026

Samuel Oviedo Paz, Santiago Alberto Rozo Silva, Isis Catitza Amaya Arbelaez
Aprendizaje de Maquina Aplicado, Universidad EAFIT
Profesor: Marco Teran, 2026

Abstract—Colombia genera cerca del 65% de su energia electrica con fuentes hidroelectricas, lo que hace al sistema vulnerable a las sequias. Ante el pronostico de un Fenomeno del Nino moderado a fuerte en el segundo semestre de 2026, con probabilidad del 90% de consolidacion en septiembre, este trabajo busca anticipar los momentos en que los embalses del Sistema Interconectado Nacional (SIN) podrian alcanzar niveles criticos. Se integran datos hidrologicos de SIMEM/XM y variables climaticas de ERA5 en un dataset de 99838 observaciones diarias por embalse (2013–2024). El analisis exploratorio evidencia una autocorrelacion fuerte y persistente del target y un rezago hidrologico entre precipitacion y nivel de reservas. El baseline con arbol de decision obtiene $RMSE=18.4$ pp y $R^2=0.454$ sobre el conjunto de prueba.

Index Terms—embalses, El Nino, aprendizaje de maquina, series de tiempo, deficit energetico, Colombia

I. PROBLEMA Y MOTIVACION

A. Pregunta de investigacion

Dado el pronostico de un Fenomeno del Nino para Colombia en 2026, **?en que momentos los embalses del SIN alcanzaran niveles criticos con riesgo de deficit energetico?**

Se trata de un problema de **regresion sobre series de tiempo multivariadas**: la variable objetivo es el porcentaje de volumen util diario de cada embalse (`reserva_pct`, 0–100%), con umbral historico de alerta operacional en el 30%.

B. Contexto y motivacion

El Fenomeno del Nino reduce las lluvias sobre las cuencas andinas y caribenas, lo que disminuye los aportes hidricos y agota progresivamente las reservas. El evento de 1992 genero el apagon mas severo en la historia del pais [6]; desde entonces la dependencia hidroelectrica no ha disminuido sustancialmente.

Las alertas para 2026 son concretas: el IDEAM y el Ministerio de Ambiente reportaron un 90% de probabilidad de consolidacion del fenomeno hacia septiembre [1], [2], con impactos crecientes desde mitad de ano. Reportes del sector documentan caidas de hasta 17 puntos porcentuales en los niveles de embalses en tres meses [5], mientras analistas advierten sobre riesgo de racionamiento si la sequia se prolonga [3], [4]. Anticipar estos momentos permite activar oportunamente plantas termicas, gestionar la demanda y planear importaciones de gas.

TABLE I
VARIABLES DEL DATASET FINAL

Variable	Tipo	Descripcion
<code>reserva_pct</code>	TARGET	% vol. util del embalse (0–100)
<code>aportes_masa</code>	Hidro	Caudal total diario en la region (m^3)
<code>media_hist_masa</code>	Hidro	Media historica del mismo periodo (m^3)
<code>aportes_vs_media</code>	Hidro	$aportes / media \times 100$; <100 = sequia
<code>t2m</code>	ERA5	Temperatura a 2 m ($^{\circ}C$)
<code>u10, v10</code>	ERA5	Viento a 10 m, zonal y meridional (m/s)
<code>wind_speed</code>	ERA5	Magnitud del viento (m/s)
<code>msl</code>	ERA5	Presion al nivel del mar (hPa)
<code>tp</code>	ERA5	Precipitacion total (mm)
<code>ro, sro</code>	ERA5	Escorrentia total y superficial (mm)
<code>swvll</code>	ERA5	Humedad vol. suelo capa 1 (m^3/m^3)
<code>sst_nino</code>	ERA5	SST region Nino 3.4 ($^{\circ}C$)

II. CONJUNTO DE DATOS

A. Fuentes

Se integraron dos fuentes complementarias.

SIMEM / XM (API oficial): datos operativos del mercado de energia mayorista colombiano. Se extraen la variable objetivo (`VolumenUtilPorcentaje`) y los aportes hidricos diarios (`AportesHidricosMasa`) mediante la libreria `pydataxm` [7]. Cobertura diaria desde 2000.

ERA5 / Copernicus (archivo local `.grib`): reanalis climatico global del ECMWF a 0.25° de resolucion diaria [8]. Se extraen ocho variables meteorologicas en el punto de grilla mas cercano a cada embalse, y la temperatura superficial del mar (SST) en la region Nino 3.4 como indicador del estado del ENSO.

B. Descripcion del dataset

El dataset final contiene **99838 filas**, una por cada combinacion (`Fecha`, `CodigoEmbalse`), con 17 columnas. Cubre el periodo 2013-01-01 a 2024-12-31 e incluye **24 embalses** del SIN en 6 regiones hidrologicas. La Tabla I describe todas las variables.

C. Adecuacion del dataset

El dataset es adecuado por cuatro razones. Primero, contiene directamente la variable objetivo tal como la reporta el operador oficial del SIN. Segundo, integra las entradas

hidrológicas del sistema y los forzamientos climáticos que las determinan, permitiendo capturar la cadena causal lluvia-escorrentia-embalse. Tercero, la resolución diaria permite detectar descensos abruptos. Cuarto, 12 años de historia incluyen múltiples ciclos de El Niño y La Niña, necesarios para aprender el patrón diferencial de sequía.

III. CALIDAD DE DATOS Y PREPROCESAMIENTO

A. Inspección de calidad

De las 17 columnas, 16 tienen 0 valores faltantes. La única excepción es `aportes_vs_media_pct` con 45 ausentes (0.05%), originados en divisiones por cero cuando la media histórica es nula. No se detectaron filas duplicadas exactas.

Se filtraron 384 registros con `reserva_pct ≤ 0` (valores físicamente imposibles o periodos fuera de servicio). El dataset de trabajo queda con **99 454 filas**.

B. Pipeline de preprocesamiento

El pipeline diferencia cuatro tipos de variables:

Numericas (13): imputación por mediana seguida de estandarización (`StandardScaler`).

CódigoEmbalse: codificación binaria (`BinaryEncoder`) para los 24 embalses, sin asumir ordinalidad.

RegiónHidrológica: codificación one-hot para las 6 regiones.

Fecha: codificación cíclica con seno y coseno del mes y del día del año:

$$\sin\left(\frac{2\pi \text{mes}}{12}\right), \cos\left(\frac{2\pi \text{mes}}{12}\right), \sin\left(\frac{2\pi \text{día}}{365}\right), \cos\left(\frac{2\pi \text{día}}{365}\right).$$

El espacio resultante tiene **28 características**.

C. Partición de datos

Holdout temporal 80/20: las observaciones se ordenan por Fecha y se asigna el 80% más antiguo a entrenamiento y el 20% más reciente a prueba (sin barajado). El identificador `SEED=72` se reserva para la inicialización de los modelos (p.ej. `random_state` del árbol de decisión).

- Entrenamiento: 79 563 filas, media target 62.54%
- Prueba: 19 891 filas, media target 62.62%

La similitud de medias confirma una partición representativa pese al corte temporal. Para la Entrega 2 se implementará una validación cruzada temporal estricta con ventanas deslizantes (`TimeSeriesSplit`) en lugar de un único corte.

IV. ANALISIS EXPLORATORIO DE DATOS

A. Perfil estadístico

`reserva_pct` tiene media 62.3% y desviación estándar 25.1 pp. El rango va de 0 a 124.4%; los valores superiores a 100 son vertimientos válidos cuando el embalse supera su capacidad. La Tabla II resume el perfil de las features numéricas más relevantes.

TABLE II
PERFIL ESTADISTICO DE FEATURES NUMERICAS CLAVE

Variable	Mediana	Std	Min	Max	Asim.
<code>reserva_pct</code>	63.2	25.1	0.0	124.4	-0.01
<code>aport._masa (M)</code>	320	537	0.0	5932	2.85
<code>aport._vs_med</code>	81.7	47.9	5.8	1252	3.83
<code>t2m</code>	24.9	4.5	12.0	38.4	0.05
<code>msl</code>	1013.6	2.6	1004.7	1025.1	0.20
<code>sst_nino</code>	27.4	1.3	21.3	30.4	-1.34
<code>tp</code>	0.10	0.99	0.0	35.7	8.72
<code>ro</code>	0.06	0.77	0.0	34.9	15.17
<code>sro</code>	0.01	0.44	0.0	27.9	19.18
<code>swvll</code>	0.40	0.09	0.09	0.53	-0.77

`aportes_masa` en millones de m³.




Fig. 1. Autocorrelación de `reserva_pct`. La dependencia se extiende por más de 300 días, confirmando la naturaleza inercial del almacenamiento hídrico.

B. Hallazgos principales

Autocorrelación fuerte y persistente. La Fig. 1 muestra que la autocorrelación de `reserva_pct` permanece significativa por más de 300 días de rezago. El nivel de almacenamiento es un proceso muy inercial: un embalse acumula y descarga agua lentamente, por lo que el nivel de hoy depende fuertemente de los niveles de días y semanas anteriores. Esto es el hallazgo más importante para el diseño del modelo.

Rezago hidrológico entre precipitación y nivel. La Fig. 2 muestra que la correlación cruzada entre `tp` y `reserva_pct` no es máxima en `lag=0` sino en lags de varios días. La lluvia no eleva el nivel del embalse instantáneamente: hay un retardo de horas a días en la propagación por la cuenca. La Fig. 3 ilustra este patrón visualmente en el embalse Betania.

Alta asimetría en variables de precipitación. `tp`, `ro` y `sro` presentan asimetrías positivas extremas (8.7, 15.2 y 19.2 respectivamente). La mayoría de los días tienen precipitación baja o nula, con eventos intensos esporádicos. Esto justificará transformaciones logarítmicas en la Entrega 2.

sst_nino como señal de fondo. La SST en Niño 3.4




Fig. 2. Correlacion cruzada entre precipitacion (tp) y nivel de reservas. El maximo se desplaza del lag=0 varios dias.




Fig. 3. Evolucion temporal de precipitacion y nivel de reservas en Betania (2013–2024). Se observan el patron estacional y el rezago hidrológico.

presenta asimetria negativa (-1.34): los episodios calidos de El Nino son mas pronunciados que los de La Nina en el periodo analizado. Esta variable actuara como senial climatica de largo plazo, complementando las seniales hidrológicas de corto plazo.

V. BASELINE

A. Justificacion de la metrica

Se reportan tres metricas complementarias:

RMSE (metrica principal): en las mismas unidades que `reserva_pct` (puntos porcentuales), es directamente interpretable. Un RMSE de 18 pp significa que el modelo se equivoca en promedio 18 pp al predecir el nivel de un embalse. Ademas, al elevar al cuadrado, penaliza con mayor fuerza los errores grandes, que son los que pueden llevar al sistema cerca del umbral critico del 30%.

MAE: interpretacion mas robusta ante valores extremos.

R^2 : fraccion de varianza del target explicada por el modelo, facilita comparaciones entre entregas.

B. Modelo baseline

El modelo baseline es un `DecisionTreeRegressor` con `max_depth=8`, aplicado sobre el pipeline de preprocesamiento descrito. Se eligio por ser rapido, interpretable y no requerir supuestos de linealidad, estableciendo un piso competitivo sin ajuste de hiperparametros.

TABLE III

RESULTADOS DEL MODELO BASELINE EN EL CONJUNTO DE PRUEBA

Modelo	RMSE (pp)	MAE (pp)	R^2
Decision Tree (depth=8)	18.36	14.28	0.454

C. Resultados

D. Interpretacion

Un R^2 de 0.454 indica que el baseline captura el 45.4% de la varianza del target; el 54.6% restante queda sin explicar. Con un RMSE de 18.4 pp sobre un umbral de alerta en 30% y una desviacion estandar del target de 25 pp, el modelo actual no es suficientemente preciso para tomar decisiones operativas.

El problema es de dificultad **moderada a alta**. La limitacion principal del baseline es la ausencia de informacion autoregresiva: el nivel de un embalse hoy depende fuertemente de su nivel ayer, pero esa informacion no esta incluida como feature. Cualquier modelo que no explote la estructura temporal tendra un techo de desempeno bajo.

VI. CONCLUSIONES PRELIMINARES

Se construyo un dataset integrado de 99 454 registros diarios para 24 embalses del SIN colombiano (2013–2024), con 13 variables climaticas e hidrológicas como features y el porcentaje de volumen util como target.

El EDA identifica tres patrones clave: la fuerte autocorrelacion temporal del target (dependencia persistente por mas de 300 dias), el rezago hidrológico entre precipitacion y nivel, y la alta asimetria de las variables de precipitacion. Estos hallazgos orientan directamente la Entrega 2: inclusion de lags del target y de `tp/ro`, transformaciones logaritmicas, y validacion temporal estricta.

El baseline con arbol de decision establece el piso de comparacion en $\text{RMSE} = 18.4 \text{ pp}$ y $R^2 = 0.454$. Los siguientes pasos incluyen incorporar variables autoregresivas y comparar al menos dos familias de modelos adicionales (regresion regularizada, gradient boosting).

REFERENCES

- [1] IDEAM, “Probable desarrollo de El Nino en el segundo semestre de 2026 activa alerta temprana,” 2026. [En línea]. Disponible en: <https://www.ideam.gov.co/sala-de-prensa/noticia/probable-desarrollo-de-el-nino-en-el-segundo-semestre-de-2026-activa-alerta-temprana>
- [2] IDEAM y Minambiente, “90% de probabilidad de llegada del Fenomeno de El Nino para septiembre,” 2026. [En línea]. Disponible en: <https://www.ideam.gov.co/sala-de-prensa/noticia/ideam-y-minambiente-alertan-de-90-de-probabilidad-de-llegada-del-fenomeno-de-el-ni>
- [3] El Tiempo, “Probabilidad de un super El Nino es del 90% en septiembre de 2026,” 2026. [En línea]. Disponible en: <https://www.eltiempo.com/vida/medio-ambiente/probabilidad-de-un-super-el-nino-es-del-90-en-septiembre-de-2026-asi-afectaria-a-la-e>
- [4] El Colombiano, “Super El Nino 2026: Colombia, embalses, apagon, gas importado,” 2026. [En línea]. Disponible en: <https://www.elcolombiano.com/negocios/super-el-nino-2026-colombia-embalses-apagon-gas-importado-BA35603288>
- [5] Portafolio, “Nivel de embalses caen de 80% a 63% en 3 meses,” 2026. [En línea]. Disponible en: <https://www.portafolio.co/energia/nivel-de-embalses-caen-de-80-a-63-en-3-meses-y-aumentan-riesgos-para-el-sistema-po>

- [6] Celsia, “Hace 30 años Colombia se apago,” 2022. [En línea]. Disponible en: <https://www.celsia.com/es/podcasts/hace-30-anos-colombia-se-apago/>
- [7] XM / Equipo Analitica, “API_XM: libreria Python para datos del mercado de energia colombiano,” 2024. [En línea]. Disponible en: https://github.com/EquipoAnaliticaXM/API_XM
- [8] ECMWF, “ERA5: data documentation,” 2024. [En línea]. Disponible en: <https://confluence.ecmwf.int/display/CKB/ERA5:+data+documentation>