

# Entrega 2: Comparación de Familias y Validación

Predicción de niveles críticos en embalses colombianos ante El Niño 2026

Samuel Oviedo Paz, Santiago Alberto Rozo Silva, Isis Catitza Amaya Arbelaez

Aprendizaje de Maquina Aplicado, Universidad EAFIT

Profesor: Marco Teran, 2026

**Abstract**—Colombia genera cerca del 65% de su energía eléctrica con fuentes hidroeléctricas, lo que hace al sistema vulnerable a las sequías. Ante el pronóstico de un fenómeno del Niño moderado a fuerte en el segundo semestre de 2026, con probabilidad del 90% de consolidación en septiembre, este trabajo busca anticipar los momentos en que los embalses del Sistema Interconectado Nacional (SIN) podrían alcanzar niveles críticos. Se integran datos hidrológicos de SIMEM/XM, variables climáticas de ERA5 en un dataset de 99 838 observaciones diarias por embalse (2013-2024), y el índice del Niño 3.4 proporcionado por NOAA. Sobre este conjunto se entrenan y comparan dos familias de modelos -- arboles (Random Forest, Extra Trees) y boosting (XGBoost, CatBoost) -- frente a un baseline Naive y un árbol de decisión. La evaluación combina holdout temporal 80/20 y validación cruzada temporal (TimeSeriesSplit). Extra Trees se selecciona como modelo provisional por su mejor desempeño en CV ( $CV\ RMSE = 23.84$ ,  $CV\ R^2 = 0.052$ ) y por una importancia de variables coherente con la dinámica hidro climática del sistema.

**Index Terms**—embalses, El Niño, aprendizaje de máquina, series de tiempo, validación cruzada temporal, ensembles, boosting, Colombia.

## I. PROBLEMA Y MOTIVACION

### A. Pregunta de investigación

Dado el pronóstico de un fenómeno del Niño para Colombia en 2026, ¿cuál será el nivel de los embalses colombianos al predecir con una ventana de un día?

Se trata de un problema de **regresión sobre series de tiempo multivariadas**: la variable objetivo es el porcentaje de volumen útil diario de cada embalse (`reserva_pct`, 0-100%), con umbral histórico de alerta operacional en el 30%.

### B. Contexto y motivación

El Fenómeno del Niño reduce las lluvias sobre las cuencas andinas y caribeñas, lo que disminuye los aportes hídricos y agota progresivamente las reservas. El evento de 1992 genero el apagón más severo en la historia del país [6]; desde entonces la dependencia hidroeléctrica no ha disminuido sustancialmente. Las alertas para 2026 son concretas: el IDEAM y el Ministerio de Ambiente reportaron un 90% de probabilidad de consolidación del fenómeno hacia septiembre [1], [2], con impactos crecientes desde mitad de año. Reportes del sector documentan caídas de hasta 17 puntos porcentuales en los niveles de embalses en tres meses [5], mientras analistas

advierten sobre riesgo de racionamiento si la sequía se prolonga [3], [4]. Anticipar estos momentos permite activar oportunamente plantas térmicas, gestionar la demanda y planear importaciones de gas.

## II. CONJUNTO DE DATOS

### A. Fuentes

Se integraron tres fuentes complementarias.

**SIMEM / XM (API oficial)**: datos operativos del mercado de energía mayorista colombiano. Se extraen la variable objetivo (`VolumenUtilPorcentaje`) y los aportes hídricos diarios (`AportesHidricosMasa`) mediante la librería `pydataxm` [7]. Cobertura diaria desde el año 2000.

**ERA5 / Copernicus (archivo local .grib)**: reanálisis climático global del ECMWF a 0.25° de resolución diaria [8]. Se extraen ocho variables meteorológicas en el punto de grilla más cercano a cada embalse, y el promedio de la temperatura superficial del mar (SST) utilizando un proxy de la región Niño 1+2 como indicador del estado del ENSO.

**índice Niño 3.4 (NOAA/CPC)**: dato mensual publicado por el *National Centers for Environmental Information* que cuantifica la anomalía de temperatura superficial del mar en la región Niño 3.4 del Pacífico tropical.

### B. Descripción del dataset

El dataset final contiene 99 839 filas, una por cada combinación (Fecha, `CodigoEmbalse`), con 18 columnas. Cubre el periodo 2013-01-01 a 2024-12-31 e incluye 24 embalses del SIN en 6 regiones hidrológicas. La Tabla I describe todas las variables.

### C. Adecuación del dataset

El dataset es adecuado por cuatro razones. Primero, contiene directamente la variable objetivo tal como la reporta el operador oficial del SIN. Segundo, integra las entradas hidrológicas del sistema y los forzamientos climáticos que las determinan, permitiendo capturar la cadena causal lluvia-escorrentía-embalse. Tercero, la resolución diaria permite detectar descensos abruptos. Cuarto, 12 años de historia incluyen múltiples ciclos de El Niño y La Niña, necesarios para aprender el patrón diferencial de sequía.

TABLE I  
VARIABLES DEL DATASET FINAL

| Variable                 | Tipo   | Descripción   |
|--------------------------|--------|---------------|
| <code>reserva_pct</code> | Target | Porcentaje de |

|                      |         |                                                                     |
|----------------------|---------|---------------------------------------------------------------------|
|                      |         | volumen útil diario del embalse (0-100%)                            |
| aportes_masa         | Feature | Caudal total diario de aportes hídricos en la región (m³)           |
| media_historica_masa | Feature | Media histórica del caudal de aportes para el mismo periodo (m³)    |
| aportes_vs_media_pct | Feature | Razón entre aportes actuales y media histórica (%)                  |
| t2m                  | Feature | Temperatura del aire a 2 metros de altura (°C)                      |
| u10                  | Feature | Componente zonal (este-oeste) del viento a 10 m (m/s)               |
| v10                  | Feature | Componente meridional (norte-sur) del viento a 10 m (m/s)           |
| msl                  | Feature | Presión atmosférica al nivel del mar (hPa)                          |
| sst_Niño12_proxy     | Feature | Proxy de SST en la región Niño 1+2 (°C)                             |
| oni_anom             | Feature | índice oceánico del Niño (ONI) NOAA/CPC; anomalía SST Niño 3.4 (°C) |
| tp                   | Feature | Precipitación total acumulada diaria (mm)                           |
| ro                   | Feature | Escorrentía total diaria (mm)                                       |
| sro                  | Feature | Escorrentía superficial diaria (mm)                                 |
| swv11                | Feature | Humedad volumétrica del suelo en la capa superficial (m³/m³)        |
| wind_speed           | Feature | Velocidad escalar del viento calculada a partir de u10 y v10 (m/s)  |

### III. CALIDAD DE DATOS Y PREPROCESAMIENTO

#### A. Inspeccion de calidad

De las 18 columnas, 17 no presentan valores faltantes. La única excepción es `aportes_vs_media_pct`, con 45 ausencias (0.05%), originadas en divisiones por cero cuando la media historica es nula. No se detectaron filas duplicadas.

Se aplicaron filtros de depuración. Primero, se eliminaron los registros correspondientes a los embalses `agregado_sin`,

Ituango, Sogamoso y El Quimbo, por no contar con datos desde 2013. Posteriormente, se descartaron registros que incumplen condiciones físicas validas, como niveles de embalse inferiores a cero. El conjunto resultante quedo conformado por 91 992 registros.

#### B. Pipeline de preprocesamiento

El pipeline diferencia cuatro tipos de variables:

**Numéricas (52):** imputación por mediana seguida de estandarización (`RobustScaler`).

**CódigoEmbalse:** codificación binaria (`BinaryEncoder`) para los 22 embalses finales, sin asumir ordinalidad.

**RegionHidrologica:** codificación one-hot para las 6 regiones.

**Fecha:** codificación cíclica con seno y coseno del mes y del día del año:  $\sin(2\pi \cdot \text{mes}/12)$ ,  $\cos(2\pi \cdot \text{mes}/12)$ ,  $\sin(2\pi \cdot \text{día}/365)$ ,  $\cos(2\pi \cdot \text{día}/365)$ .

El espacio de características resultante luego del *feature engineering* tiene **67 características**.

#### C. Partición de datos

Holdout temporal 80/20: las observaciones se ordenan por fecha y se asigna el 80% más antiguo a entrenamiento y el 20% más reciente a prueba, sin barajado. El identificador `SEED=72` se reserva para la inicialización de los modelos (p. ej. `random_state` del árbol de decisión).

Entrenamiento: 73 445 filas, media target 62.48%. Prueba: 18 262 filas, media target 61.71%. La similitud de medias confirma una partición representativa pese al corte temporal. Adicionalmente, se realiza una validación cruzada temporal estricta con ventanas deslizantes (`TimeSeriesSplit`), descrita en la Sección IV-D.

## IV. METODOLOGIA

#### A. Recolección y preparación de datos

El dataset se construye a partir de las tres fuentes descritas en la sección II: datos de embalses (SIMEM/XM), variables meteorológicas (ERA5/Copernicus) e índice ENSO (NOAA/CPC). Las fuentes se fusionan considerando tanto la ubicación espacial del dato (longitud, latitud) como la fecha, dado que el dataset tiene frecuencia temporal diaria.

#### B. Tratamiento inicial de los datos

Se realiza un filtrado inicial eliminando cuatro embalses que no cubren el rango temporal completo del dataset: `AgregadoSin`, `Ituango`, `Sogamoso` y `ElQuimbo`. Adicionalmente, se descartan registros que incumplen condiciones físicas validas. La variable objetivo del problema es `reserva_pct`.

#### C. Preprocesamiento

Los valores atípicos se tratan mediante eliminación. Posteriormente, los registros se ordenan cronológicamente y se dividen en conjuntos de entrenamiento y prueba en una

proporción 80/20, respetando la secuencia temporal para evitar fuga de información (*data leakage*).

El preprocesamiento se aplica exclusivamente sobre el conjunto de entrenamiento e incluye la codificación de variables nominales y de fecha, y el escalado de variables numéricas mediante `RobustScaler`. Adicionalmente, se lleva a cabo una etapa de *feature engineering* orientada a construir variables de persistencia temporal, estacionalidad, memoria hidrológica y tendencias climáticas.

#### D. Validación cruzada

Se implementa validación cruzada temporal mediante `TimeSeriesSplit`, lo que permite simular escenarios reales de predicción utilizando observaciones pasadas para predecir observaciones futuras. En cada fold, la ventana de entrenamiento se expande progresivamente, manteniendo el orden cronológico y descartando cualquier filtración de datos del futuro hacia el pasado.

#### E. Algoritmos de aprendizaje de maquina

Se entrenaron modelos de dos familias de algoritmos:

**Familia basada en arboles:** Extra Trees y Random Forest.

**Familia de Boosting:** XGBoost y CatBoost.

Como líneas base del problema se emplean Decision Tree y un baseline Naive (persistencia de un día).

#### F. Métricas de evaluación

Para cada modelo se calculan las métricas RMSE, MAE,  $R^2$  y MASE. Adicionalmente, se generan visualizaciones comparativas entre modelos y análisis de predicciones individuales, con el fin de complementar la evaluación numérica con un análisis visual del desempeño de cada algoritmo.

#### G. Consideraciones

Dada la naturaleza temporal e hidrológica del problema, se adoptaron las siguientes decisiones metodológicas: se prescinde de una partición aleatoria de los datos, se preserva el orden cronológico en todo momento, y se incorporan variables de rezago (*lag*) y ventanas móviles (*rolling windows*) para capturar la inercia del sistema y mitigar el data leakage.

### V. CONFIGURACION EXPERIMENTAL

#### A. XGBoost

Se configuro un regresor XGBoost con objetivo `reg:squarederror` y 700 árboles con tasa de aprendizaje de 0.03, profundidad máxima de 5 y mínimo de 3 muestras por hoja. Para controlar el sobreajuste se aplica submuestreo del 85% (`subsample` y `colsample_bytree`), regularización L1 ( $\alpha = 0.05$ ) y L2 ( $\lambda = 1.0$ ). El entrenamiento emplea el método histograma (`hist`) con 256 bins. Al ser invariante al escalado, el preprocesamiento omite la estandarización y conserva la imputación por mediana y las codificaciones categórica y temporal.

#### B. Random Forest

Se configuro un regresor Random Forest con 300 árboles, profundidad máxima de 18, mínimo de 10 muestras para dividir un nodo y 4 muestras por hoja. La selección de variables en cada división utiliza la raíz cuadrada del total de características (`max_features="sqrt"`) y se emplea muestreo con reemplazo (`bootstrap=True`). Al igual que XGBoost, este algoritmo es invariante al escalado, por lo que el preprocesamiento conserva únicamente la imputación por mediana y las codificaciones categórica y temporal.

#### C. Extra Trees

Se configuro un regresor Extra Trees con 500 árboles, profundidad máxima de 24, mínimo de 6 muestras para dividir un nodo y 2 muestras por hoja. A diferencia de Random Forest, utiliza umbrales de división aleatorios y no emplea muestreo con reemplazo (`bootstrap=False`), lo que incrementa la diversidad del ensemble y reduce la varianza. La selección de variables por nodo se realiza igualmente mediante raíz cuadrada (`max_features="sqrt"`). El preprocesamiento conserva únicamente la imputación por mediana y las codificaciones categórica y temporal.

### VI. RESULTADOS COMPARATIVOS

Sobre el conjunto de prueba único, los tres modelos de ensemble obtuvieron resultados prácticamente equivalentes entre sí. Extra Trees y XGBoost empataron en RMSE (21.40) y Random Forest quedo a menos de una centésima (21.43), con  $R^2$  alrededor de 0.31 en los tres casos y valores de MASE entre 5.12 y 5.27. El Baseline Decision Tree, sin ensemble ni regularización, fue el peor modelo con un RMSE de 24.02, MAE de 18.73 y  $R^2$  de 0.13. El Naive Baseline, con RMSE de 6.23, MAE de 3.24 y  $R^2$  de 0.941, supero ampliamente a todos los modelos de aprendizaje automático, lo que a primera vista podría interpretarse como un fracaso del enfoque, pero que hemos llegado a concluir que es un resultado esperable en series con alta autocorrelación diaria: cuando el horizonte de predicción es de un día, el valor del día anterior contiene una fracción enorme de la información disponible.

TABLE II  
RESULTADOS SOBRE EL CONJUNTO DE PRUEBA (HOLDOUT 20%)

| Modelo      | RMSE  | MAE   | $R^2$ | MASE |
|-------------|-------|-------|-------|------|
| Naive       | 6.23  | 3.24  | 0.941 | 1.00 |
| Baseline    |       |       |       |      |
| Extra Trees | 21.40 | 16.58 | 0.309 | 5.12 |
| XGBoost     | 21.40 | 17.07 | 0.309 | 5.27 |
| Random      | 21.43 | 17.04 | 0.307 | 5.26 |
| Forest      |       |       |       |      |
| Baseline    | 24.02 | 18.73 | 0.130 | --   |
| Decision    |       |       |       |      |
| Tree        |       |       |       |      |


Sin embargo, el panorama se matiza al evaluar mediante validación cruzada temporal. Aquí Extra Trees obtuvo el menor CV RMSE (23.84) y el mayor CV  $R^2$  (0.052), seguido

de cerca por Random Forest (CV RMSE 24.15, CV R<sup>2</sup> 0.031). XGBoost presento el peor desempeño en este escenario, con CV RMSE de 25.50 y un R<sup>2</sup> medio negativo (-0.077), lo que indica que en promedio no supera a una predicción por la media global cuando se lo evalúa sobre pliegues temporales distintos.

TABLE III  
RESULTADOS DE VALIDACION CRUZADA TEMPORAL  
(TIMESERIESPLIT)

| Modelo        | CV RMSE | CV R <sup>2</sup> |
|---------------|---------|-------------------|
| Extra Trees   | 23.84   | 0.052             |
| Random Forest | 24.15   | 0.031             |
| XGBoost       | 25.50   | -0.077            |

La diferencia entre el R<sup>2</sup> en prueba única (~0.31) y en validación cruzada (~0.05) es el hallazgo más importante de esta etapa, dado que los modelos actuales son sensibles al periodo de evaluación y su capacidad de generalización a través del tiempo es aún limitada. Este comportamiento es consistente con lo que se observa visualmente en la comparación de predicciones en un periodo acotado para el caso de AGREGADO\_BOGOTA -- elegido por su alta representatividad -- donde Random Forest y Extra Trees siguen razonablemente la dinámica real, mientras que XGBoost subestima sistemáticamente el nivel de reserva durante todo el periodo, señal de que su ajuste depende fuertemente del subconjunto de datos sobre el que fue entrenado.



VII. EXPLICACION TECNICA


El análisis de importancia de variables muestra que cada algoritmo aprendió a apoyarse en señales distintas, lo cual es informativo sobre las fortalezas y limitaciones de cada enfoque.

**Random Forest** concentra su peso en la tendencia de mediano plazo del caudal afluente (num\_aportes\_masa\_ma30, num\_media\_historica\_masa) y en variables climáticas ERA5 como humedad del suelo y temperatura superficial, lo que sugiere que privilegia la inercia hidrológica del sistema.

**Extra Trees**, en cambio, da mayor protagonismo a la diferenciación regional, coincidiendo en la importancia del caudal afluente y priorizando el índice ONI con sus lags temporales de 1 y 7 días, capturando más explícitamente la variabilidad climática interanual asociada a fenómenos como El Niño y La Niña, cuyo impacto en los caudales de Colombia es bien documentado.

**XGBoost** depende fuertemente de la región hidrológica y de las variables temporales cíclicas, y es el único modelo que incorpora variables de déficit hídrico entre sus features más relevantes.

Esta divergencia entre modelos sugiere que ninguno logra integrar de forma completa todas las señales disponibles, y que hay información complementaria que podría aprovecharse mejor con una ingeniería de features más dirigida en una futura entrega.



El rendimiento limitado en validación cruzada tiene una explicación estructural que va más allá del ajuste de hiperparámetros. El problema central es que ninguno de los modelos tiene acceso a los lags más actuales de la reserva hídrica (`reserva_pct` en  $t-1$ ) como feature explícita, que es precisamente la información que el Naive Baseline usa para alcanzar  $R^2$  de 0.941. Los modelos de ensamble aprenden patrones climáticos e hidrológicos genuinamente valiosos, pero sin anclar la predicción al estado actual del embalse compiten en desventaja estructural contra la persistencia simple.

A esto se suma la heterogeneidad entre embalses. El modelo único entrenado para todo el sistema debe capturar comportamientos muy distintos entre ríos de alta montaña, sistemas de piedemonte y cuencas caribeñas, lo que presiona el error promedio al alza. Finalmente, la ausencia de regularización explícita más allá de los hiperparámetros por defecto contribuye a la inestabilidad observada en XGBoost entre pliegues, donde pequeñas diferencias en la distribución de los datos de entrenamiento producen variaciones importantes en el desempeño.

## VIII. DECISION FINAL Y LIMITACIONES

Extra Trees se selecciona como modelo base para continuar en la siguiente entrega. Su elección se sustenta en tres criterios:

**1) Mejor desempeño en validación cruzada temporal**, la métrica más confiable para estimar la capacidad de generalización real del modelo dado el carácter temporal de los datos.

**2) Importancia de variables coherente** con el conocimiento hidrológico del sistema colombiano, incorporando tanto la inercia de mediano plazo del caudal como la señal ENSO, lo que genera mayor confianza en que el modelo está aprendiendo patrones genuinos y no artefactos del conjunto de entrenamiento.

**3) Desempeño equivalente** sobre el set de prueba único al de los demás modelos ML, por lo que no hay costo en adoptarlo como referencia.

Random Forest se mantiene como comparador activo dada su cercanía en validación cruzada y su mayor estabilidad relativa entre pliegues. XGBoost, por su inestabilidad y  $R^2$  medio negativo en validación cruzada, requiere una revisión más profunda de su configuración antes de poder considerarse competitivo.

Las limitaciones abiertas que orientan la siguiente entrega son tres. Primero, el techo de desempeño de los ensambles ante el Naive Baseline indica que la incorporación controlada de lags del target (con bloqueo estricto de leakage temporal) es la palanca con mayor impacto potencial. Segundo, el modelo único globaliza embalses con regímenes hidro climáticos muy distintos; una segmentación por región o por embalse podría reducir el error medio. Tercero, la variabilidad entre folds, especialmente en XGBoost, sugiere explorar regularización

más fuerte y alternativas lineales regularizadas (Ridge y Lasso) como referencia explícita para juzgar si la complejidad de los ensambles está justificada. En particular, Lasso, al permitir una selección automática de variables, puede reducir el ruido introducido por features poco informativas y mejorar la estabilidad en validación cruzada.

## . REFERENCES

- [1] IDEAM, "Probable desarrollo de El Niño en el segundo semestre de 2026 activa alerta temprana," 2026. [En línea]. Disponible en: <https://www.ideam.gov.co/sala-de-prensa/noticia/probable-desarrollo-de-el-Niño-en-el-segundo-semestre-de-2026-activa-alerta-temprana>
- [2] IDEAM y Minambiente, "90% de probabilidad de llegada del Fenomeno de El Niño para septiembre," 2026. [En línea]. Disponible en: <https://www.ideam.gov.co/sala-de-prensa/noticia/ideam-y-minambiente-alertan-de-90-de-probabilidad-de-llegada-del-fenomeno-de-el-ni>
- [3] El Tiempo, "Probabilidad de un super El Niño es del 90% en septiembre de 2026," 2026. [En línea]. Disponible en: <https://www.eltiempo.com/vida/medio-ambiente/probabilidad-de-un-super-el-Niño-es-del-90-en-septiembre-de-2026-asi-afectaria-a-la-e>
- [4] El Colombiano, "Super El Niño 2026: Colombia, embalses, apagon, gas importado," 2026. [En línea]. Disponible en: <https://www.elcolombiano.com/negocios/super-el-Niño-2026-colombia-embalses-apagon-gas-importado-BA35603288>
- [5] Portafolio, "Nivel de embalses caen de 80% a 63% en 3 meses," 2026. [En línea]. Disponible en: <https://www.portafolio.co/energia/nivel-de-embalses-caen-de-80-a-63-en-3-meses-y-aumentan-riesgos-para-el-sistema-po>
- [6] Celsia, "Hace 30 años Colombia se apagó," 2022. [En línea]. Disponible en: <https://www.celsia.com/es/podcasts/hace-30-anos-colombia-se-apago/>
- [7] XM / Equipo Analítica, "API\_XM: librería Python para datos del mercado de energía colombiano," 2024. [En línea]. Disponible en: [https://github.com/EquipoAnaliticaXM/API\\_XM](https://github.com/EquipoAnaliticaXM/API_XM)
- [8] ECMWF, "ERA5: data documentation," 2024. [En línea]. Disponible en: <https://confluence.ecmwf.int/display/CKB/ERA5:+data+documentation>