

Entrega 3: Modelo Final, Interpretación y Comunicación

Predicción de niveles críticos en embalses colombianos ante El Niño 2026

Samuel Oviedo Paz, Santiago Alberto Rozo Silva, Isis Catitza Amaya Arbelaez

Aprendizaje de Maquina Aplicado, Universidad EAFIT

Profesor: Marco Teran, 2026

Abstract—Colombia genera cerca del 65% de su energía eléctrica con fuentes hidroeléctricas, lo que hace al sistema vulnerable a las sequías. Ante el pronóstico de un fenómeno del Niño moderado a fuerte en el segundo semestre de 2026, con probabilidad del 90% de consolidación en septiembre, este trabajo busca anticipar los momentos en que los embalses del Sistema Interconectado Nacional (SIN) podrían alcanzar niveles críticos. Se integran datos hidrológicos de SIMEM/XM, variables climáticas de ERA5 en un dataset de 99 838 observaciones diarias por embalse (2013-2024), y el índice del Niño 3.4 proporcionado por NOAA. Sobre este conjunto se entrenan y comparan dos familias de modelos -- árboles (Random Forest, Extra Trees) y boosting (XGBoost, LightGBM) -- frente a un baseline ingenuo y un árbol de decisión, bajo un esquema de holdout temporal con horizonte común de cinco meses y validación cruzada temporal (TimeSeriesSplit). LightGBM se selecciona como modelo final por su mejor desempeño global (RMSE = 20.51, $R^2 = 0.43$) y la mayor robustez en validación cruzada (CV RMSE = 20.40, CV $R^2 = 0.278$).

Index Terms—embalses, El Niño, aprendizaje de máquina, series de tiempo, gradient boosting, LightGBM, validacion cruzada temporal, interpretabilidad, Colombia.

I. PROBLEMA Y MOTIVACIÓN

A. Pregunta de investigación

Dado el pronóstico de un fenómeno del Niño para Colombia en 2026, ¿cuál será el nivel de los embalses colombianos al predecir con una ventana de un día?

Se trata de un problema de **regresión sobre series de tiempo multivariadas**: la variable objetivo es el porcentaje de volumen útil diario de cada embalse (reserva_pct, 0-100%).

B. Contexto y motivación

El Fenómeno del Niño reduce las lluvias sobre las cuencas andinas y caribeñas, lo que disminuye los aportes hídricos y agota progresivamente las reservas. El evento de 1992 genero el apagón más severo en la historia del país [6]; desde entonces la dependencia hidroeléctrica no ha disminuido sustancialmente. Las alertas para 2026 son concretas: el IDEAM y el Ministerio de Ambiente reportaron un 90% de probabilidad de consolidación del fenómeno hacia septiembre [1], [2], con impactos crecientes desde mitad de año. Reportes del sector documentan caídas de hasta 17 puntos porcentuales en los niveles de embalses en tres meses [5], mientras analistas

advierten sobre riesgo de racionamiento si la sequía se prolonga [3], [4]. Anticipar estos momentos permite activar oportunamente plantas térmicas, gestionar la demanda y planear importaciones de gas.

TABLE I
VARIABLES DEL DATASET FINAL

Variable	Tipo	Descripción
reserva_pct	Target	Porcentaje de volumen útil diario del embalse (0-100%)
aportes_masa	Feature	Caudal total diario de aportes hídricos en la región (m³)
media_historica_masa	Feature	Media histórica del caudal de aportes para el mismo periodo (m³)
aportes_vs_media_pct	Feature	Razón entre aportes actuales y media histórica (%)
t2m	Feature	Temperatura del aire a 2 metros de altura (°C)
u10	Feature	Componente zonal del viento a 10 m (m/s)
v10	Feature	Componente meridional del viento a 10 m (m/s)
msl	Feature	Presión atmosférica al nivel del mar (hPa)
sst_Niño12_proxy	Feature	Proxy de SST en la región Niño 1+2 (°C)
oni_anom	Feature	Índice Oceánico del Niño (ONI) NOAA/CPC; anomalía SST Niño 3.4 (°C)
tp	Feature	Precipitación total acumulada diaria (mm)
ro	Feature	Escorrentía total diaria (mm)
sro	Feature	Escorrentía superficial diaria (mm)
swvl1	Feature	Humedad

wind_speed	Feature	volumetrica del suelo en la capa superficial (m ³ /m ³) Velocidad escalar del viento (a partir de u10 y v10) (m/s)
------------	---------	--

II. CONJUNTO DE DATOS

A. Fuentes

Se integraron tres fuentes complementarias.

SIMEM / XM (API oficial): datos operativos del mercado de energía mayorista colombiano. Se extraen la variable objetivo (`VolumenUtilPorcentaje`) y los aportes hídricos diarios (`AportesHidricosMasa`) mediante la librería `pydataxm` [7]. Cobertura diaria desde el año 2000.

ERA5 / Copernicus (archivo local .grib): reanálisis climático global del ECMWF a 0.25° de resolución diaria [8]. Se extraen ocho variables meteorológicas en el punto de grilla más cercano a cada embalse, y el promedio de la temperatura superficial del mar (SST) utilizando un proxy de la región Niño 1+2 como indicador del estado del ENSO.

Índice Niño 3.4 (NOAA/CPC): dato mensual publicado por el *National Centers for Environmental Information* que cuantifica la anomalía de SST en la región Niño 3.4 del Pacífico tropical.

B. Descripción del dataset

El dataset final contiene 99 839 filas, una por cada combinación (Fecha, `CodigoEmbalse`), con 18 columnas. Cubre el periodo 2013-01-01 a 2024-12-31 e incluye 24 embalses del SIN en 6 regiones hidrológicas. La Tabla I describe todas las variables.

C. Adecuación del dataset

El dataset es adecuado por cuatro razones. Primero, contiene directamente la variable objetivo tal como la reporta el operador oficial del SIN. Segundo, integra las entradas hidrológicas del sistema y los forzamientos climáticos que las determinan, permitiendo capturar la cadena causal lluvia-escorrentía-embalse. Tercero, la resolución diaria permite detectar descensos abruptos. Cuarto, 12 años de historia incluyen múltiples ciclos de El Niño y La Niña, necesarios para aprender el patrón diferencial de sequía.




Fig. 1. Integración de las tres fuentes de datos en el dataset final.

III. PREPROCESAMIENTO

A. Pipeline de preprocesamiento

El pipeline diferencia cuatro tipos de variables:

Numéricas (97): imputación por mediana seguida de estandarización (`RobustScaler`).

CodigoEmbalse: codificación binaria (`BinaryEncoder`) para los 22 embalses finales, sin asumir ordinalidad.

RegionHidrologica: codificación one-hot para las 6 regiones.

Fecha: codificación cíclica con seno y coseno del mes y del día del año: $\sin(2\pi \cdot \text{mes}/12)$, $\cos(2\pi \cdot \text{mes}/12)$, $\sin(2\pi \cdot \text{día}/365)$, $\cos(2\pi \cdot \text{día}/365)$.

El espacio de características resultante luego del *feature engineering* tiene **100 características**.

B. Partición de datos

Se emplea una estrategia de holdout temporal basada en una fecha de corte común para todos los embalses. En lugar de dividir el conjunto según una proporción fija (p. ej. 80/20), se definió como conjunto de prueba la información correspondiente a los últimos cinco meses del periodo disponible, mientras que todas las observaciones anteriores se asignaron al conjunto de entrenamiento. Esta estrategia garantiza que todos los embalses sean evaluados sobre el mismo horizonte temporal y evita inconsistencias derivadas de que distintos embalses poseen cantidades distintas de observaciones y rangos temporales variables.

La fecha de corte se calculó restando cinco meses a la fecha más reciente del conjunto de datos, de modo que el entrenamiento contiene únicamente información histórica disponible antes del horizonte de evaluación, reproduciendo un escenario realista de predicción futura y evitando filtraciones temporales (*data leakage*). El identificador `SEED = 72` se reservó para la inicialización reproducible de los modelos con componentes aleatorios. Adicionalmente, se realizó una validación cruzada temporal estricta mediante ventanas deslizantes (`TimeSeriesSplit`), descrita en la Sección IV-D.

IV. METODOLOGÍA

A. Recolección y preparación de datos

El dataset se construye a partir de las tres fuentes descritas en la Sección II. Las fuentes se fusionan considerando tanto la ubicación espacial del dato (longitud, latitud) como la fecha, dado que el dataset tiene frecuencia temporal diaria.

B. Tratamiento inicial de los datos

Se realiza un filtrado inicial eliminando cuatro embalses que no cubren el rango temporal completo: `AgregadoSin`, `Ituango`, `Sogamoso` y `ElQuimbo`. Adicionalmente, se descartan registros que incumplen condiciones físicas válidas. La variable objetivo es `reserva_pct`.

C. Preprocesamiento de datos

Los valores atípicos se tratan mediante eliminación. Los registros se ordenan cronológicamente y se dividen usando la fecha de corte común: el conjunto de prueba corresponde a los últimos cinco meses y el de entrenamiento a todas las observaciones anteriores. El preprocesamiento se ajusta exclusivamente sobre el conjunto de entrenamiento y luego se aplica al de prueba; incluye la codificación de variables nominales y temporales y el escalado mediante `RobustScaler`. Adicionalmente, se realiza una etapa de *feature engineering* orientada a capturar persistencia temporal, estacionalidad, memoria hidrológica y tendencias climáticas, incorporando tanto dependencias históricas como comportamientos cíclicos del fenómeno.

D. Validación cruzada

Se implementa validación cruzada temporal mediante `TimeSeriesSplit`, lo que permite simular escenarios reales de predicción usando observaciones pasadas para predecir observaciones futuras. En cada fold, la ventana de entrenamiento se expande progresivamente, preservando el orden cronológico.

E. Algoritmos de aprendizaje de maquina

Se entrenaron modelos de dos familias: la familia basada en árboles, con Extra Trees y Random Forest, y la familia de boosting, con XGBoost y LightGBM.

Adicionalmente, se utilizó una **línea base ingenua (naive baseline)** como referencia, prediciendo el valor futuro a partir de la observación más reciente disponible. Esta referencia permite verificar que los modelos aportan capacidad predictiva real.

F. Métricas de evaluación

Para cada modelo se calculan RMSE, MAE, R^2 y MASE. Adicionalmente, se generan visualizaciones comparativas y análisis de predicciones individuales, complementando la evaluación numérica con un análisis visual del desempeño.

G. Consideraciones

Dada la naturaleza temporal e hidrológica del problema, se prescinde de una partición aleatoria, se preserva el orden cronológico en todo momento, y se incorporan variables de rezago (*lag*) y ventanas móviles (*rolling windows*).

V. CONFIGURACIÓN EXPERIMENTAL

A. XGBoost

Regresor XGBoost con objetivo `reg:squarederror`, 700 árboles, tasa de aprendizaje 0.03, profundidad máxima 5 y mínimo de 3 muestras por hoja. Para controlar el sobreajuste se aplica submuestreo del 85% (`subsample` y `colsample_bytree`), regularización L1 ($\alpha = 0.05$) y L2 ($\lambda = 1.0$). El entrenamiento emplea el método histograma (`hist`) con 256 bins. Al ser invariante al escalado, el preprocesamiento omite la estandarización.

B. Random Forest

Regresor Random Forest con 300 árboles, profundidad máxima 18, mínimo de 10 muestras para dividir un nodo y 4 por hoja. La selección de variables por división usa la raíz cuadrada del total (`max_features="sqrt"`) con muestreo con reemplazo (`bootstrap=True`). Invariante al escalado.

C. Extra Trees

Regresor Extra Trees con 500 árboles, profundidad máxima 24, mínimo de 6 muestras para dividir un nodo y 2 por hoja. Utiliza umbrales de división aleatorios y no emplea muestreo con reemplazo (`bootstrap=False`), lo que incrementa la diversidad del ensemble y reduce la varianza. La selección de variables por nodo se realiza mediante raíz cuadrada (`max_features="sqrt"`).

D. LightGBM

Regresor LightGBM con 500 árboles, tasa de aprendizaje 0.05 y 64 hojas por árbol (`num_leaves=64`). Para controlar el sobreajuste se fijó un mínimo de 20 muestras por hoja y submuestreo del 80% de observaciones y variables (`subsample=0.8`, `colsample_bytree=0.8`). El entrenamiento usa gradient boosting basado en histogramas, eficiente y de menor costo computacional. Al igual que los demás modelos de árboles, es invariante al escalado.

VI. RESULTADOS COMPARATIVOS

Sobre el conjunto de prueba único, los modelos de ensemble superaron claramente al modelo base de árbol de decisión. LightGBM obtuvo el mejor desempeño general (RMSE 20.51, MAE 15.57, R^2 0.43), indicando una mayor capacidad para explicar la variabilidad del objetivo. XGBoost ocupó el segundo lugar (RMSE 21.97, R^2 0.35), seguido por Random Forest (RMSE 22.09, R^2 0.34) y Extra Trees (RMSE 22.33, R^2 0.32). Aunque las diferencias entre estos tres últimos son pequeñas, LightGBM presentó una ventaja consistente tanto en error como en capacidad explicativa.

El Baseline Decision Tree, sin mecanismos de ensemble ni regularización, fue el modelo de menor desempeño (RMSE 25.19, MAE 19.12, R^2 0.14). Estos resultados confirman el beneficio de los métodos de ensemble basados en árboles para capturar las relaciones no lineales y dependencias temporales presentes en los datos hidrológicos. La estrategia de gradient boosting de LightGBM permite explotar de manera más eficiente la información contenida en las variables de persistencia temporal, estacionalidad, memoria hidrológica y tendencias climáticas incorporadas durante la ingeniería de características.




Fig. 2. Error de prueba (RMSE) por modelo. LightGBM (naranja) obtiene el menor error; el árbol de decisión base (gris) es la referencia inferior.

TABLE II

RESULTADOS SOBRE EL CONJUNTO DE PRUEBA (HOLDOUT 5 MESES)

Modelo	RMSE	MAE	R ²	MASE
LightGBM	20.51	15.57	0.430	4.72
XGBoost	21.97	16.20	0.346	4.90
Random Forest	22.09	17.28	0.339	5.23
Extra Trees	22.33	15.90	0.324	4.82
Baseline Decision Tree	25.19	19.12	0.140	—

A. Validación cruzada temporal (TimeSeriesSplit)

La diferencia entre el desempeño en el conjunto de prueba único y en la validación cruzada temporal es un hallazgo relevante. Aunque los modelos alcanzaron R^2 entre 0.32 y 0.43 en la evaluación final, los resultados de validación cruzada fueron más conservadores, con R^2 medios entre 0.23 y 0.28. No obstante, la brecha observada es considerablemente menor que en experimentos previos, lo que sugiere una mejora en la capacidad de generalización temporal. LightGBM obtuvo el mejor desempeño promedio (CV RMSE 20.40, CV R^2 0.278), seguido de Random Forest (CV RMSE 20.68, CV R^2 0.255) y XGBoost (CV RMSE 20.77, CV R^2 0.250), mientras que Extra Trees presentó el menor poder explicativo (CV R^2 0.230). En conjunto, los modelos mantienen un comportamiento relativamente estable a través de distintos periodos, siendo LightGBM el más robusto en ambas evaluaciones.




Fig. 3. R^2 en prueba (holdout) frente a R^2 medio en validación cruzada temporal. La brecha es moderada y LightGBM domina en ambos esquemas.

TABLE III

VALIDACIÓN CRUZADA TEMPORAL (TIMESERIESPLIT)

Modelo	CV RMSE	CV R ²
LightGBM	20.40	0.278
Random Forest	20.68	0.25
XGBoost	20.77	0.250
Extra Trees	21.01	0.231

VII. DISCUSIÓN

Durante esta iteración se realizaron varios experimentos orientados a mejorar la generalización. Uno de los cambios más importantes fue la modificación de la estrategia de partición: inicialmente se empleaba una división proporcional (80/20), pero posteriormente se adoptó una partición basada en una ventana temporal fija de cinco meses para el conjunto de prueba. Esta decisión permitió que todos los embalses fueran evaluados sobre el mismo horizonte temporal, evitando inconsistencias derivadas de la diferente longitud de las series y proporcionando una evaluación más realista del desempeño futuro.

Adicionalmente, se exploraron estrategias de modelado más específicas entrenando modelos independientes por región hidrológica y por embalse individual. Sin embargo, estos enfoques produjeron resultados inferiores al modelo global. Este comportamiento sugiere que una parte importante de la capacidad predictiva proviene de patrones compartidos entre distintos embalses y regiones, aprovechados por el modelo conjunto, que parece beneficiarse de aprender relaciones comparativas y comportamientos comunes presentes en todo el sistema hidrológico nacional.

También se realizaron múltiples pruebas de ajuste de hiperparámetros sobre los modelos de ensamble. Aunque algunas configuraciones produjeron variaciones menores en las métricas, ninguna logró mejoras significativas respecto a la configuración seleccionada. Esto sugiere que las principales limitaciones actuales no están en el ajuste fino de los algoritmos, sino en la información disponible para el

aprendizaje y en la complejidad inherente del problema de predicción hidrológica. En conjunto, las mayores oportunidades de mejora futura probablemente provengan de nuevas estrategias de representación de información hidrológica y climática, más que de modificaciones adicionales en la arquitectura o en los hiperparámetros.

VIII. EXPLICACIÓN TÉCNICA

El análisis de importancia de variables evidencia que los modelos aprendieron patrones hidrológicos y climáticos consistentes, aunque con énfasis diferentes. Las variables relacionadas con la persistencia temporal de los aportes hídricos, las medias móviles históricas y los indicadores climáticos derivados de ERA5 se ubicaron entre las más relevantes, confirmando que la dinámica de los embalses depende tanto de la memoria hidrológica del sistema como de las condiciones meteorológicas recientes.




Fig. 4. Importancia de variables del modelo Random Forest (ensamble de arboles representativo de la familia), agrupada por tipo de señal: memoria hidrológica, clima ERA5 y estacionalidad.

Los modelos basados en arboles (Random Forest y Extra Trees) otorgaron una importancia significativa a las variables asociadas al caudal afluente y a las tendencias de mediano plazo, reflejando su capacidad para capturar relaciones no lineales y patrones de persistencia. Por su parte, LightGBM y XGBoost mostraron una mayor capacidad para combinar información de múltiples fuentes, incorporando simultáneamente variables climáticas, temporales y regionales en sus decisiones de partición. Esta capacidad de integración probablemente explica el mejor desempeño de LightGBM en la evaluación final y en la validación cruzada.

Los resultados sugieren que las variables diseñadas durante el feature engineering aportan información predictiva relevante. La mejora respecto al árbol de decisión base confirma que las características de estacionalidad, memoria hidrológica, tendencias climáticas y comportamiento histórico permiten capturar patrones complejos del sistema de embalses colombiano.

La validación cruzada temporal mostro una disminución del desempeño respecto a la prueba final, pero mantuvo R^2 entre 0.23 y 0.28, considerablemente superiores a los de versiones preliminares. Esto indica que, aunque existe sensibilidad a los

cambios temporales en las condiciones hidro climáticas, los modelos lograron una generalización razonable sobre periodos no observados. No obstante, persisten limitaciones estructurales: el modelo único debe aprender el comportamiento de embalses en regiones hidrológicas muy diferentes -- sistemas andinos, cuencas de piedemonte y embalses con dinámicas climáticas regionales distintas --, lo que incrementa la complejidad del aprendizaje y limita el desempeño máximo alcanzable por un único modelo global.

IX. DECISIÓN FINAL, LIMITACIONES Y RECOMENDACIONES

LightGBM se selecciona como el modelo final del proyecto. Su elección se fundamenta en tres criterios principales:

1) Mejor desempeño global, al obtener simultáneamente el menor RMSE (20.51) y el mayor R^2 (0.43) sobre el conjunto de prueba, superando a XGBoost, Random Forest y Extra Trees.

2) Mayor capacidad de generalización temporal, evidenciada por la validación cruzada (CV RMSE 20.40, CV R^2 0.278), con comportamiento consistente a través de distintos periodos.

3) Aprovechamiento efectivo de la información disponible, integrando variables hidrológicas, climáticas, temporales y regionales mediante gradient boosting.

Los resultados permiten concluir que los modelos de ensamble constituyen una alternativa viable para la predicción de reservas hídricas, siendo LightGBM el que ofreció el mejor equilibrio entre precisión y robustez bajo el esquema de evaluación temporal empleado.

No obstante, el estudio presenta limitaciones. Primero, el modelo global debe representar simultáneamente embalses con comportamientos hidrológicos y climáticos muy diferentes, lo que dificulta capturar patrones específicos de cada sistema. Segundo, aunque se incorporaron variables de persistencia, estacionalidad y clima, la capacidad predictiva sigue dependiendo de la calidad y disponibilidad de la información histórica. Tercero, la diferencia entre el desempeño en prueba final y en validación cruzada indica que aún existe sensibilidad a los cambios temporales en las condiciones hidrometeorológicas, una limitación inherente a los modelos entrenados sobre datos históricos en entornos dinámicos y no estacionarios.

Como recomendaciones, se sugiere incorporar variables que representen de manera más directa el estado reciente de los embalses, así como fuentes complementarias de información hidrometeorológica que enriquezcan la representación del sistema. Asimismo, conviene evaluar arquitecturas especializadas para series temporales, como redes recurrentes o transformadores temporales, para comparar su capacidad de capturar dependencias de largo plazo frente a los ensambles. Finalmente, se recomienda mantener esquemas de validación estrictamente temporales y horizontes de prueba homogéneos para todos los embalses, ya que este enfoque proporciona una

estimación más realista de la generalización del modelo en escenarios operativos reales.

REFERENCES

- [1] IDEAM, "Probable desarrollo de El Niño en el segundo semestre de 2026 activa alerta temprana," 2026. [En línea]. Disponible en: <https://www.ideam.gov.co/sala-de-prensa/noticia/probable-desarrollo-de-el-Niño-en-el-segundo-semestre-de-2026-activa-alerta-temprana>
- [2] IDEAM y Minambiente, "90% de probabilidad de llegada del Fenomeno de El Niño para septiembre," 2026. [En línea]. Disponible en: <https://www.ideam.gov.co/sala-de-prensa/noticia/ideam-y-minambiente-alertan-de-90-de-probabilidad-de-llegada-del-fenomeno-de-el-ni>
- [3] El Tiempo, "Probabilidad de un super El Niño es del 90% en septiembre de 2026," 2026. [En línea]. Disponible en: <https://www.eltiempo.com/vida/medio-ambiente/probabilidad-de-un-super-el-Niño-es-del-90-en-septiembre-de-2026-asi-afectaria-a-la-e>
- [4] El Colombiano, "Super El Niño 2026: Colombia, embalses, apagon, gas importado," 2026. [En línea]. Disponible en: <https://www.elcolombiano.com/negocios/super-el-Niño-2026-colombia-embalses-apagon-gas-importado-BA35603288>
- [5] Portafolio, "Nivel de embalses caen de 80% a 63% en 3 meses," 2026. [En línea]. Disponible en: <https://www.portafolio.co/energia/nivel-de-embalses-caen-de-80-a-63-en-3-meses-y-aumentan-riesgos-para-el-sistema-po>
- [6] Celsia, "Hace 30 años Colombia se apago," 2022. [En línea]. Disponible en: <https://www.celsia.com/es/podcasts/hace-30-anos-colombia-se-apago/>
- [7] XM / Equipo Analítica, "API_XM: libreria Python para datos del mercado de energia colombiano," 2024. [En línea]. Disponible en: https://github.com/EquipoAnaliticaXM/API_XM
- [8] ECMWF, "ERA5: data documentation," 2024. [En línea]. Disponible en: <https://confluence.ecmwf.int/display/CKB/ERA5:+data+documentation>