

Predicción de niveles críticos en embalses colombianos ante El Niño 2026

Modelo final, interpretación y comunicación · Aprendizaje de Máquina Aplicado — Universidad EAFIT


Samuel Oviedo Paz · Santiago Alberto Rozo Silva · Isis Catitza Amaya Arbeláez | Prof. Marco Terán, 2026

1 · EL PROBLEMA

Colombia genera ~65% de su electricidad con hidroeléctricas, lo que la hace vulnerable a las sequías. Para 2026 el IDEAM reporta 90% de probabilidad de un El Niño fuerte hacia septiembre, con riesgo de racionamiento.

Pregunta: ¿cuál será el nivel de reserva de cada embalse del SIN al predecir con una ventana de un día? Es un problema de regresión sobre series de tiempo multivariadas; el objetivo es reserva_pct (0–100%), con alerta operacional en 30%.

2 · LOS DATOS




Tres fuentes: SIMEM/XM (reserva y aportes), ERA5/Copernicus (8 variables meteo + SST) y NOAA/CPC (índice ONI). Dataset final: 91 992 observaciones diarias, 22 embalses, 2013–2024, 100 características.

3 · MÉTODO Y VALIDACIÓN

- Partición temporal con horizonte común: los últimos 6 meses son prueba; todo lo anterior, entrenamiento (igual horizonte para todos los embalses).
- Sin barajado: se preserva el orden cronológico para evitar fuga de información (data leakage). RobustScaler ajustado solo en train.
- Feature engineering: lags, medias móviles, estacionalidad cíclica y memoria hidrológica → 100 características.
- Dos familias: árboles (Random Forest, Extra Trees) y boosting (XGBoost, LightGBM), frente a un baseline ingenuo y un árbol de decisión.
- Validación cruzada temporal estricta (TimeSeriesSplit) con ventana expansiva.
- Métricas: RMSE, MAE, R^2 y MASE.

4 · RESULTADOS — ERROR POR MODELO


Error de prueba (RMSE) — menor es mejor



Los cuatro ensambles superan ampliamente al árbol de decisión base (RMSE 25.19). LightGBM logra el menor error (RMSE 20.51; MAE 15.57), seguido de XGBoost (21.97), Random Forest (22.09) y Extra Trees (22.33).

5 · GENERALIZACIÓN (PRUEBA vs. VALIDACIÓN CRUZADA)

Capacidad explicativa y generalización



La brecha entre prueba (R^2 0.32–0.43) y validación cruzada (R^2 0.23–0.28) es moderada y mucho menor que en entregas previas: la generalización temporal del modelo mejoró de forma clara. LightGBM domina en ambos esquemas (CV RMSE 20.40, CV R^2 0.278).

6 · MODELO FINAL: LightGBM

20.51

RMSE

0.43

R^2 prueba


0.278

CV R^2

gradient boosting · 500 árboles · 64 hojas · learning rate 0.05 · submuestreo 0.8. Invariante al escalado; entrenamiento por histogramas.

7 · VARIABLES QUE EXPLICAN EL DESEMPEÑO

Importancia de variables — Random Forest



8 · CONCLUSIONES Y QUÉ SIGUE

- Mejor modelo: LightGBM, por menor error y mayor poder explicativo, consistente en prueba y validación cruzada.
- Confiabilidad: generaliza razonablemente en el tiempo; el R^2 baja en CV pero la brecha es moderada. Persiste sensibilidad a regímenes hidroclimáticos.
- Qué lo explica: memoria hidrológica (medias móviles de aportes), clima ERA5 (humedad de suelo, temperatura, precipitación) y señal ENSO/ONI.
- Para mejorar/desplegar: incorporar el estado reciente del embalse, más fuentes hidrometeorológicas y evaluar modelos de series temporales (RNN/Transformers); conservar validación estrictamente temporal.

github.com/SamuelOviedo2003/ml-embalses-colombia